

AV 데이터 분포 진단

Phase 0 결과 요약

100,398 clips

experiments/EXP-003/phase0/output/

1 · ODD 커버리지 분석

이 데이터셋은 운영설계영역(ODD) 조합 공간을 얼마나 커버하는가?

Step 0-F · 100,398 clips

1 · ODD 스키마 정의 — 11필드 값 분포

AV 지각·예측·계획 난이도로 정의한 **11개 ODD 필드**. 각 막대 = 값의 **클립 비율**(좌 → 우 빈도순, 100% 누적) · 지배값이 막대를 꽉 채울수록 편중이 심함.




표 분석 — 11개 필드 모두 값이 등장하고 lighting · junction_proximity · road_type · traffic_density 는 2~4개 값이 비교적 고르게 분포(채워짐). 반면 나머지 7개 필드는 **단일 지배값에 80~99.97% 쏠림**(clear 92% · low 99% · cars_only 97% · none 99.97% 등) — 값은 있으나 다양성은 없는 구조. 특히 안전 크리티컬 값(high·absent·poor·VRU)은 막대에서 실선 수준으로만 존재 → 커버리지 저조의 직접 원인.

1 · ODD 커버리지 정량화 — 도출 & 결과

질문: AV 안전성은 *\"마주칠 조건 조합을 얼마나 학습했나\"*에 좌우 → ODD를 이산 필드로 정의하고 **관측 / 이론** 조합 비율(커버율)을 측정.

도출 4단계

① 클립 → 11-튜플 (각 클립 = 11필드 값 1튜플)

(urban, clear, well_lit, cars_only, sparse, post_junction, dry, low, good, none, clear)

↑ **최빈 조합** · 6,578클립(6.55%)이 이 하나에 몰림

② 중복 제거 → **2,070 고유 조합** (싱글톤 897 / 반복 1,173)

③ 이론 = 값 수의 곱 $5 \times 5 \times 4 \times 6 \times 4 \times 5 \times 4 \times 4 \times 4 \times 5 \times 4 = 15,360,000$

④ 커버율 = $2,070 / 15.36M = 0.013\%$ (클립 0.167%)

필드 정의를 바꿔도 결론 동일 — 비교군 대비

필드 정의	필드	관측	이론	클립 커버율
비교군 ①	19	7,240	2.4×10^{11}	0.0008%
비교군 ②	9	1,384	614,400	2.26%
본 분석 스키마	11	2,070	15.36M	0.167%

결론은 스키마와 무관. 필드 9·11·19개 어느 정의든 커버율 극저(최대 2.26%). 필드를 늘릴수록 이론 조합만 폭증하고 관측은 정체 → 커버율은 오히려 하락. 즉 저커버리지는 **데이터의 구조적 결함**.

15.36M

이론 조합
가능한 전체 조합 (값 수의 곱)

2,070

관측 조합
실제 등장 · 커버율 0.013%

99.987%

미관측 조합
이론 중 한 건도 없음

2,070개 중 **897개(43.3%)**는 **싱글톤**, 최빈 조합 하나(urban·clear·well_lit·cars_only·sparse·...)에만 **6,578클립(6.55%)** 집중 = Gap-3(ODD 커버리지 저조)의 정량적 근거.

1 · 결과 ② — 상위 조합 집중 & 최빈 top 20

중복 집중도

구분	조합 수	클립 수	평균 클립/조합	비고
싱글톤(1회)	897	897	1.0	조합 43.3%·클립 0.9%
반복(2회+)	1,173	99,501	84.8	클립 99.1%
상위 100	100	86,372	863.7	전체 86.0%

최빈 top 1-10 (클립 · %)

#	클립	%	road_type·lighting·traffic_density·junction_proximity
1	6,578	6.55	urban·well_lit·sparse·post_junction
2	5,935	5.91	rural·well_lit·sparse·none
3	5,217	5.20	rural·moderate·sparse·none
4	4,878	4.86	rural·well_lit·sparse·post_junction
5	4,185	4.17	rural·moderate·sparse·post_junction
6	3,955	3.94	urban·moderate·sparse·post_junction
7	3,914	3.90	urban·well_lit·moderate·post_junction
8	2,489	2.48	highway·well_lit·sparse·none
9	2,436	2.43	urban·well_lit·moderate·in_junction
10	2,306	2.30	urban·moderate·moderate·post_junction

top 11-20 (클립 · %)

#	클립	%	road_type·lighting·traffic_density·junction_proximity
11	2,288	2.28	highway·well_lit·moderate·none
12	2,245	2.24	urban·well_lit·moderate·approaching
13	2,165	2.16	highway·moderate·sparse·none
14	1,970	1.96	rural·moderate·sparse·none·wet
15	1,769	1.76	rural·poorly·sparse·none·poor
16	1,675	1.67	rural·poorly·sparse·none
17	1,551	1.54	urban·moderate·moderate·approaching
18	1,530	1.52	urban·well_lit·sparse·in_junction
19	1,503	1.50	highway·moderate·moderate·none
20	1,401	1.40	urban·well_lit·sparse·approaching

* 14·15위만 5개 항목 — 평소 고정되던 필드가 뒤집혀 5번째 값 추가(14위 road_surface=wet · 15위 visibility=poor).

11필드 = 고정 7 + 변동 4

완전 고정 4 (데이터 전체)
weather=clear · agent_type=cars_only · occlusion=low · special_event=none

top 20 내 사실상 고정 3
road_surface=dry · visibility=good · lane_marking=clear (14위 wet·15위 poor만 예외)

변동 4 → 순위 결정
road_type · lighting · traffic_density · junction_proximity

상위 20 조합조차 전부 정상 상황의 변주 — 첫 비정상은 14·15위(wet·poor). top 100에서도 완전 고정 필드는 2개뿐(occlusion=low·event=none), 나머지 9개는 값이 갈리나 정상 조건 내에 국한.

1 · 결과 ③ — 필드 편향 · 미관측 값 · 수집 우선순위

필드별 편향

필드	지배 값	비중	진단
weather	clear=92,314	91.9%	비·눈·안개 거의 없음
agent_type	cars_only=97,402	97.0%	VRU 극소 (보행 268·자전거 97)
occlusion_level	low=99,467	99.1%	고폐색 전무
special_event	none=100,361	99.96%	accident·emergency 0건
lane_marking	clear=95,109	94.7%	차선 불량 극소 (absent 252)

미관측 스키마 값 — 전혀 등장하지 않는 값

필드	미관측 값	의미
special_event	accident · emergency	사고·긴급 상황 클립이 데이터에 전무

special_event 의 obstacle 은 관측됨. accident · emergency 는 100,398클립 전체에서 단 한 건도 없음.

수집 우선순위 (ODD 커버리지 관점) — 관측 비율이 극히 낮거나 전무한 조합 = 데이터 수집 우선 타깃

우선	타깃 조건	현재 클립 수	비고
최우선	special_event=accident / emergency	0	안전 크리티컬 — 전체 데이터에 단 1건도 없음
최우선	occlusion_level=high	123	고폐색 = 지각 모델 직접 실패 · 상위 100 조합 전체 부재
최우선	traffic_density=dense + weather=rain/snow	~148	혼잡+악천후 복합 (독립 분포 기반 추정)
높음	agent_type=cyclists / pedestrians (VRU)	97 / 268	취약 도로 이용자 — VRU 예측 학습 데이터 극소
높음	lane_marking=absent	252	차선 탐지 모델 완전 실패 구간
높음	weather=snow / fog	1,600 / 1,263	동절기·안개 시나리오 극소
높음	road_type=national_road	242	거의 미수집

표 작성 근거 — 각 등급은 정량 + 정성의 결합이다. 정량 (코드로 검증) = 관측 클립 수(step_a 실측) · 상위 100 조합 부재(analyze_top100). 정성 (도메인 판단 · 코드 metric 없음) = 안전 크리티컬 · 모델 실패 유발 · 취약 · 성능 저하 등 심각도 서술 전부.

등급 부여: ● 최우선 = [정성] 안전 크리티컬 + [정량] 상위 100(86%)에서조차 전무(고정 = occlusion=low·special_event=none뿐) · ● 높음 = [정성] 모델 실패 취약 + [정량] 관측 극소 · ● 중간 = [정성] 성능 저하 + [정량] 관측 존재(본 표 제외).

※ 등급은 관측 수로 정하지 않음 — ● snow(1,600)·fog(1,263)가 ● medium(807)·wet(414)보다 데이터가 더 많은데도 더 높은 등급. 즉 등급을 가르는 건 관측 수(정량)가 아니라 심각도(정성). 비교 열 = AV 성능 영향(정성) + 관측 상태(step_a 실측·정량, ~는 추정).

2 · 임베딩 벡터 기반 분포 분석

캡션 임베딩 공간에서 데이터가 얼마나 중복되고 몇 방향을 커버하는가?

Effective N (중복·유효 크기) · Vendi (의미 다양성)

2 · Effective N — 계산 원리

$$\text{Effective N} = \sum_{i=1}^N w_i \quad (0 \leq \text{Effective N} \leq N), \quad \bar{s}_i = \frac{1}{K} \sum_{j=1}^K \text{sim}(x_i, \text{NN}_j)$$

$$\underbrace{w_i = 1 - \bar{s}_i}_{\text{soft}} \quad \underbrace{w_i = \frac{1}{1 + \#\{\text{sim} > 0.95\}}}_{\text{hard}}$$

직관: 각 클립을 독립 클립 몇 개 분량(0~1)으로 세어 더한 값.

공통 빠대는 $\sum w_i$, **차이는 w_i 계산법** — soft = 평균 유사도 감점, hard = 근접복제(sim>0.95) 개수 감점. count는 상위 K=20 중(자기 제외), 범위 0~K → hard $w_i \in [1/21, 1]$.

입력 & 계산 — 임베딩 유사도만 사용 (ODD·캡션 텍스트 직접 안 씀)

재료: `embeddings.npy` (N×1024, bge-m3 캡션 임베딩, L2 정규화)

→ ① **k-NN** (FAISS): 각 클립의 **상위 20이웃 유사도** 반환 (평균 아직 X) → `knn_sim` (N×K)

→ ② **집계** (`knn_sim` 만 입력): soft = 20이웃 유사도 **평균**, hard = `sim>0.95` **개수**

예시 (클립 #5, `knn_sim[5]=[0.98, 0.97, ..., 0.91]`) — 같은 이웃, 두 방식:

soft: 20이웃 평균 0.945 → $w=1-0.945=$ **0.055** · **hard:** `sim>0.95` 이웃 3개 → $w=1/(1+3)=$ **0.25**

요약: ① k-NN이 각 클립의 가장 가까운 20개 이웃 + 유사도를 찾음 → ② 그 20개로 w_i 계산 — **soft** = 유사도 평균으로 감점(연속), **hard** = 그 중 `sim>0.95` 개수로 감점(이진).

soft-hard는 같은 스케일 — 둘 다 $\sum w_i$ 이고 w_i = "이 클립을 독립 클립 몇 개로 칠까"(0~1)로 의미가 같다. 완전 고유 → $w_i=1$, 완전 중복 → $w_i=0$ 으로 **끝점(눈금)이 동일** → 결과 단위가 같은 "독립 클립 수 $\in [0, N]$ ". 그래서 **6,021 vs 55,766 = 같은 분모의 6% vs 56%**, 직접 비교가 정당하다(차이는 오직 애매한 중간=회색시대 판정).

2 · Effective N — 목적 & 결과

목적 — 왜 재나 "10만 클립 = 실질 정보 몇 개 분량인가" 정량화. 중복 많으면 클립 수↑라도 실질 정보량↓ → ① **유효 크기** 추정 ② **pruning 여지** 판단. 중복 기준 엄격도만 달리한 두 버전을 **범위**로 봄 — **Hard**=관대(상한, `sim>0.95` 복제만) · **Soft**=엄격(하한, 평균 유사도 연속 감점). 격차 = 부드러운 중복량 진단.

결과 — 전체 100,398 클립의 실질 정보량

6.0%

Soft (엄격·하한)
Effective N = 6,021

56%

Hard (관대·상한)
Effective N = 55,766

Soft 기준 나머지 94%는 반복 정보 · Hard 기준 나머지 44%는 반복 정보

왜 6% ↔ 56%로 벌어지나 — 격차 ≈5만 클립 = '애매하게 닮은(near-중복)' 장면의 양. **차이는 판정 엄격도뿐**:

- **Hard**(관대) — 거의 똑같은 복사본(`sim>0.95`)만 중복 처리 → **55,766** 남김
- **Soft**(엄격) — `0.90~0.95` 미묘하게 닮은 장면까지 깎음 → **6,021** 남김
- 📷 **비유** — 연사(burst) 10장: Hard는 **10장** · Soft는 사실상 **1장**으로 셈
- **이 데이터셋** — '도심 직진'류 연사형 장면 수만 장 → Soft에서만 대량 필터 → 격차 발생

(Yao et al., *SoftDedup*, ACL 2024)

⚠ 한계 — 단독으로 믿으면 안 되는 이유

- **정체** — 각 클립이 **K=20** 이웃만 보는 **로컬** 통계
- **가능** "중복이 얼마나 많나(질량)" · **불가** "독립 덩어리가 몇 개인가(글로벌)"
- **약점** — K·유사도에 민감 → **클러스터 크기 ≈ K면 값 왜곡**

예) 거의 같은 클립 **21장** 그룹이 **4,762개**(총 10만) → 직관 답 "독립 ≈ 4,762". 그러나 K=20이면 각 클립이 **1-0.98=0.02장**으로만 세어져 합계 ≈**2,000** = 참값(4,762)도 총수(10만)도 아닌 **K에 휘둘린 값**.

✓ 보완

1. **Vendi 병행(주)** — 글로벌 스펙트럼으로 "덩어리 몇 개"를 직접 포착. *Effective N*을 **단독으로 안 쓰는 이유**.
2. **K-민감도** — K=10/20/40으로 다시 세어 값이 크게 흔들리면 "클러스터 크기 ≈ K" 경고. 쉽게: 자(K)를 바꿨더니 잔 값이 달라지면 그 값은 못 믿는다.
3. **그룹 수가 필요하면** — 유사도 τ 이상 닮은 클립끼리 사슬처럼 이어붙여 **덩어리 개수를 직접 셈**(연결요소). 쉽게: A~B, B~C면 A~C도 한 무리 — 친구의 친구까지 사슬로 이어 붙이면 연사 500장도 통째로 1덩어리.

결론 — 로컬(Effective N) + 글로벌(Vendi)을 반드시 함께.

2 · Vendi — 계산 원리

① 유사도 표(커널 K) 만들기

- **뽑기** — 10만 전부는 너무 커(10만² 불가) → 임의 **2,000개 클립** 추출(Nyström 근사)
- **비교** — 2,000개 벡터(bge-m3, L2정규화)를 **서로서로 코사인 유사도** → **2000×2000 표 K**
- **의미** — $K[i, j]$ = "클립 i·j가 얼마나 닮았나" (1=똑같음 · 0=무관 · 대각선=자기=1)

🔍 **직관**: K = "닮음 지도". 닮은 클립 많음 → 행/열 평행 → **랭크 낮음** → 다음 단계 **고유값 λ가 소수 축에 쏠림**. (Effective N과 같은 임베딩, 보는 각도만: 개별 이웃 → 전체 스펙트럼)

② 이 표 K에서 다양성 뽑기 — 아래 수식으로 계산

$$\text{Vendi} = \exp(H(\mathbf{p})) = \exp\left(-\sum_i p_i \log p_i\right), \quad p_i = \frac{\lambda_i}{\sum_j \lambda_j} \quad (\lambda = \text{유사도 커널 } K \text{의 고유값})$$

K의 고유값 λ를 3토막으로 읽으면 위 수식이 곧 **"독립 방향 수"**

λ_i : 방향별 크기

각 독립 축에 데이터가 퍼진 정도(에너지). 큰 λ = 그 방향에 데이터가 몰림.

→

p_i = λ_i/Σλ : 방향별 비중

합=1로 정규화 → "전체 다양성 중 이 방향이 차지하는 몫".

→

exp(H) : "균등 몇 개짜리와 맞먹나"로 환산

균등 4방향 → **4** · 한 방향 97% 쏠림 → **≈1** ⇒ **실제로 일하는 방향 수**
∴ 지배항 ln0.97≈0 · 1%항은 비중엔 놀림 ⇒ H≈0 ⇒ exp(H)≈1

🔑 **"균등하게 k개면 정확히 k"** → 그래서 exp(H)는 "실질적으로 몇 개 방향인가"를 재는 **soft 카운트**다. 주사위가 고르면 6, 한 눈에 쏠리면 ≈1로 나오는 **'유효 선택지 수'**와 같은 원리(= Hill number·유효 종 수).

🔧 **Vendi 눈금** — 모든 클립 동일 → **1** · k개 독립 그룹(균등) → **k** · 2,000개 전부 독립 → **2000** | 고유값이 **소수에 쏠릴수록 값↓**(좁은 공간) · **고를수록 값↑**(넓은 커버리지)

③ 안정화 — 재현 가능한 값인가

앵커 2,000개를 다시 뽑아 여러 번 반복, run 간 **표준오차/평균 < 2%**면 수렴 → 샘플링에 흔들리지 않는 안정값 (이번 3전략 모두 5회 만에 수렴, Sequential Stopping Rule).

10 / 18

2 · Vendi — 목적 · 결과 · 해석

목적 — 왜 재나 Effective N은 중복 질량(로컬)만 본다 → "몇 개의 독립 의미 방향인가"(글로벌)는 Vendi가 답. 같은 공식에 앵커를 3가지 방식으로 뽑아, 다양성 부족의 원인을 **중복 vs 커버리지**로 분해한다.

결과 — Vendi 3전략 (독립 의미 방향 수)

셋 다 같은 Vendi 공식(p_{11}) · 다른 건 앵커 2,000개를 어떻게 뽑나뿐

3.53	3.64	4.75
random — 10만서 균등 무작위 2,000개 = 현재 분포(모델이 받는 다양성)	dedup — 고유성 가중 뽑기(혼한↓·회귀↑) = Effective N 가중치(w)를 반영한 분포	topk — 고유성 상위 풀 에서 2,000개 = Effective N 상위 6,021개 (다양성 상한)

억압계수 **1.030**($\text{dedup} \div \text{random}$) — 중복 다 지워도 **+3.0%뿐** · 이상적 큐레이션 상한(topk)조차 **4.75**

어떻게 읽나 — 진단 2단계 → 처방으로 읽는다:

- ① **원인 배분** — 억압계수 **1.030**($\text{dedup} \div \text{random}$) → 중복을 완전히 지워도 다양성은 **+3.0%뿐** → **중복은 범인이 아니다**.
- ② **낮은 천장** — 중복을 완벽히 지운 상한(topk)조차 **4.75**(이상적 AV셋은 수십~수백) → 고유 알맹이도 사실상 **3~5개 방향**(‘도심 직진’ 지배)뿐.
- ③ **처방** — 부분집합 재조정으론 천장을 못 올림 → **없는 시나리오를 새로 수집·합성**해야 다양성이 오른다.

① 진단(원인 배분) · ② 진단(천장 낮음) 이 함께여야 ③ 처방이 선다 · (Friedman & Dieng, *Vendi Score*, TMLR 2023)

🔗 **Effective N과 병합 해석 — 로컬 고유성 ≠ 글로벌 다양성** 개별 클립이 안 겹쳐도(로컬) 전체는 좁은 공간에 몰릴(글로벌) 수 있다. Eff N **6,021개조차** Vendi로 보면 **3~4방향**에만 집중.

	Vendi 높음	Vendi 낮음
Eff N 높음	✅ 이상적	⚠ 좁은 공간에 퍼짐
Eff N 낮음	⚠ 방향만 있고 빈약	❌ 이번 데이터셋

결론 — 두 지표가 같은 진단(극히 좁은 공간 집중). **로컬(Eff N) + 글로벌(Vendi)**을 반드시 **함께** 봐야 "중복 vs 커버리지"를 갈라 처방할 수 있다.

3 · 두 렌즈의 상호보완

조건 커버리지(ODD) × 내용 다양성(임베딩) — 왜 반드시 함께 봐야 하나

3 · 실증 ① — ODD엔 '같은 조건', 임베딩엔 '다른 장면'

개념 주장이 아니라 **측정**. 가장 흔한 ODD 조합 **1개**를 떼어, 그 안의 임베딩 다양성을 쟀다.

가장 흔한 ODD 셀 6,578클립 — ODD 튜플이 완전 동일 (urban·clear·cars_only·sparse·post_junction...)



"임베딩 다양성 = 의미없는 노이즈 착각 아니냐?" - 아니다

검증: 6,578개를 임베딩으로 **2그룹**으로 나눠, 각 그룹 캡션의 **대표어(TF-IDF)**로 이름 붙임 →

정차·노변주차 3,163 parked · street	교차로 통과주행 3,415 traffic · intersection
--	--

주행 판단이 **전혀 다른 상황**인데 **ODD 11축엔 이 구분이 없다** (ODD엔 날씨·조명 같은 '조건'만, 정차/통과 같은 기동·장면 축은 없음) → 노이즈가 아니라 실제 **장면 내용(content)**.

※ TF-IDF: 각 그룹 캡션에서 **그 그룹에만 유독 자주 나오는 단어**를 추출(ego·road 등 전체 공통어는 제외) → 그룹의 정체를 한 줄로 요약

직교성 — 상관이 아니라 메커니즘

임베딩이 ODD를 따른다면 셀 안 Vendi는 **1로 붕괴**해야 한다 → 관측 **3.17**(전역의 90%), 안 붕괴 → **임베딩 방향 ⊥ ODD 셀**. "임베딩=노이즈"설 반박. (단, 이걸 셀 1개 근거 — 전체 엄밀값은 다음 장 ㄱ)

3 · 실증 ②(대칭) & 결론 — 양방향 blind spot

대칭 검증 — 이번엔 임베딩이 "같다"고 본 이웃 안에서 ODD가 걸리는가.

임베딩상 가장 닮은 이웃 20개 — 평균 유사도 0.94 ("임베딩상 거의 같음")

그 이웃끼리도 ODD 11필드 중
평균 1.8개 다름
(무작위는 3.2개)

→

ODD 다양성 **55.3% 보존**
+ 가장 닮은 이웃 20개 묶음에
다른 ODD 조합 평균 ~11개

ODD 조합이 같은 클립들 — 전수 분산분석 η^2 ("조합이 같아도 화면은 판판")

ODD 조합으로 설명되는
임베딩 다양성
21%뿐
(η^2 · 순열귀무 2%)

→

임베딩 다양성 **80%가 ODD 밖**
실증①의 90%는 top셀 편향
→ 엄밀값 **80%**로 교정

계산·우연/싱글톤 검증 ▶ 부록 C

고정한 렌즈 / 방법	남는 상대 다양성
ODD 셀 고정 (실증①)	임베딩 90%
임베딩 이웃 고정 (실증②)	ODD 55%
ODD 전체 η^2 (실증④)	임베딩 80% 밖

	임베딩갭 O	임베딩갭 X
ODD갭 O	실수집 최우선 S10-S11	실수집 S6-S1
ODD갭 X	합성 S9-S7	무시

수집/합성/무시 = 두 플래그 **동시** 요구

양방향·전체 모두 큰 잔차 → **진짜 상호보완** (세 증거 **90 / 55 / 80%** 수렴).

결론 — 양자화기(ODD)와 잔차(임베딩). 임베딩은 ODD가 버린 셀 내부 변주를, ODD는 임베딩이 못 하는 **명명·외부앵커**를 잔다. 데이터의 진짜 좌표는 **둘의 곱**이지 어느 하나가 아니다. 단, 둘 다 캡션 파생 → 완전 독립 검증은 제3 신호 (egomotion).

부록

§3-2 Vendi 수식 유도 · §7 산출물 파일 가이드

`results_interpretation.md` 참조

부록 A · Vendi 3전략 — 앵커 2,000개 뽑는 법

세 전략은 모두 같은 Vendi 공식(=커널 고유값 엔트로피) · 다른 건 어떤 2,000개를 앵커로 뽑느냐뿐. `rng.choice(N, 2000, replace=False, p=?)` 의 **p**(뽑힐 확률)만 달라진다.

전략	앵커 뽑는 법 (p)	뜻
random	p=None — 10만 전체서 균등 무작위	현재 분포 그대로
dedup	p ∝ 고유성 w — 가중 추출	Effective N 가중치(w) 반영 분포
topk	상위 6,021개 풀 → 그 안에서 균등	Effective N 상위 6,021개 (다양성 상한)

① dedup — 각 클립에 w를 매기고, w에 비례해 뽑는다

- **w 계산** — 클립마다 $w = 1 - (\text{상위 } 20\text{이웃 평균 유사도})$ (Effective N 값 재사용). 중복 $w \approx 0$ · 희귀 $w \approx 1$.
- **확률화** — $p = w / \sum w \rightarrow$ 10만 클립 각자 확률 하나 = 길이 10만 벡터 `probs` (합=1).
- **뽑기** — `rng.choice(N, 2000, replace=False, p=probs)` → w 큰(희귀) 클립이 대부분 뽑힘.

클립 예	이웃 평균 유사도	$w = 1 - \text{유사도}$	뽑힐 확률 (막대 ∝ w)
중복 클립	0.98	0.02	거의 0
보통 클립	0.60	0.40	중간
희귀 클립	0.05	0.95	높음

 **직관:** 고유성만큼 **제비를 나눠주고** 2,000장 뽑는 셈 → 중복은 제비가 거의 없어 안 뽑힘. 삭제가 아니라 **확률로 눌러** "중복 제거된 셋에서 뽑은 것"과 동등 = **SoftDedup**.

② topk — "고유성 상위 6,021개 풀"은 어떻게?

- **1단계 풀 만들기** — 고유성 w 상위 6,021개(= Effective N 개수) 클립만 골라 **고정 풀**로 추출 → "실질적으로 독립인 클립"만 모은 집합.
- **2단계 뽑기** — 그 풀(6,021) 안에서 **균등 무작위 2,000개** (`p=None`).

 **직관:** 가장 고유한 클립만 남긴 **정예 집합**에서ぜん 다양성 → "이상적으로 중복을 다 걷어냈을 때 도달 가능한 **상한**". 그래서 `topk(4.75) > dedup(3.64) > random(3.53)`.

부록 B · 밀도 & LID — 계산 방법과 타당성

밀도·LID는 클립마다 하나씩 계산(각각 길이 10만 벡터, 클립당 값 1개) → 사분면 딱지도 클립별. 두 축 모두 표준·피어리뷰 방법 · 임계값도 데이터 주도(GMM+BIC) — 방법은 견고, 단 초고밀도가 LID를 혼든다.

밀도(density) — kNN 커널밀도 프록시

- `density = knn_sim[:, :10].mean()` = 가장 가까운 10개 이웃과의 평균 코사인 유사도.
- 높음 = 이웃이 바짝 붙음 = **붐빔**. "반경 안 밀집도"를 "이웃이 얼마나 가깝나"로 잰 **표준 KDE 프록시**.

LID — Ma et al. (ICLR'18) MLE

- `LID = -1 / mean(log(r_j / r_max))`, 이웃 20개 거리로 추정.
- 이웃 거리가 **고르면** → **LID↑**(다양·고차원) · **퍼지면** → **LID↓**(단조). 극값이론 기반 정식 추정량.

축	방법 타당성	이 데이터에서 신뢰
밀도	높음 — 표준 KDE 프록시, 단조·견고	비교적 신뢰 가능
LID	높음 — 학술 검증된 MLE	주의 — 초고밀도로 동적 범위 소실

⚠ **핵심 맹점** — 이웃 거리가 0.05~0.07로 거의 균일 → `r_j/r_max ≈ 1` → LID 추정량이 수치 발산(→200 클리핑, FLIPD 발산과 동근원). `lid_reliable=100%` 는 이걸 못 잡는다 — 그 플래그는 "희소·고립"(r_max 큼)만 거를 뿐, "거리 범위가 좁아 불안정"은 통과. + 모든 축이 **캡션 임베딩(bge-m3) 프록시**(ODD 정렬 ρ≈0.2, 부분). → **실무: 밀도 축 > LID 축, LID 기반 Q2/Q3-FLIPD 승격은 보수적으로.**

부록 C · η^2 (실증④) — ODD가 같으면 화면도 같을까

질문: ODD 조합(11필드)이 같은 클립들은, 실제로 서로 비슷하게 보일까? 답부터: 거의 아니다 — ODD로 설명되는 화면 다양성은 ~20%뿐, 나머지 80%는 조합이 같아도 땀판이다. 이 설명력을 통계의 η^2 (설명된 분산 비율)로 재고, 우연히 부풀려진 값이 아님까지 검증했다.

① η^2 란? — "조합별로 나눠 담고, 조합만으로 얼마나 설명되나"

- 클립마다 ODD 조합이 하나씩(예: 맑음×주간×고속도로) → 10만 클립을 2,070개 조합으로 나눠 담는다.
- 만약 ODD가 화면을 완전히 결정한다면 → 같은 조합 클립의 임베딩이 한 점에 겹치고(서로 코사인 ≈ 1 → 조합 안 분산 = 0), 모든 다양성은 조합끼리 차이에서만 나온다.
- 전체 다양성 = (조합끼리 벌어짐) + (조합 안 흩어짐)으로 놓고, 그중 "조합끼리 벌어짐"의 몫이 전체 다양성을 얼마나 표현하나(η^2)를 측정.
- 계산 — 조합끼리 벌어짐: 조합마다 평균점을 구해 (조합 평균 - 전체 평균) 2 을 조합 크기만큼 가중 합산. 조합 안 흩어짐: 각 클립과 제 조합 평균 사이 거리 2 의 총합. (거리 = 임베딩 코사인)

② 왜 섞어서 다시 재나 — "작은 조합의 착시" 견어내기

- 조합 2,070개 중 상당수가 클립 1개짜리. 1개짜리 조합은 "안 차이"가 자동 0 → 잘게 쪼갤수록 의미 없이 η^2 가 부풀어 오른다.
- 그래서 ODD 라벨을 무작위로 뒤섞어(조합 크기는 그대로, 의미만 제거) η^2 를 다시 쟀다 = "우연이면 이만큼"인 바닥값(귀무).
- 바닥값이 2.1%뿐 → 관측 21%의 거의 전부가 진짜 신호. 보정 η^2 = (관측-귀무)/(1-귀무).
- 확인사살: 1개짜리 조합 다 빼고 50개 이상 조합(169개)만으로 재계산 → 값 안 흔들림.

지표	값	의미
η^2 관측	21.3%	ODD 셀이 설명하는 임베딩 분산
η^2 순열귀무	2.1%	무의미 그룹의 우연 바닥값 (인플레이 작음 ✓)
η^2 보정	19.6%	우연 제거 후 ODD 순수 기여
η^2 (≥ 50 클립 169셀)	18.7%	싱글톤 빼도 일관 ✓

세 방식(21%·20%·19%)이 ~20% 근처로 일치 → 우연·싱글톤 아티팩트가 아닌 견고한 실제 신호. → ODD는 임베딩 분산의 ~20%만 설명, ~80%가 ODD 밖.

해석 — 두 포인트

- (A) 조합 안에 80%가 남는다 = 상호보완의 정량 증거. 날씨·조명·노면이 같아도 화면 다양성의 80%가 흩어짐 → 임베딩은 ODD엔 없는 다른 축(장면 내용·가려짐·모호한 교차로)을 추가로 본다.
- (B) 앞 장(실증①)을 스스로 교정. 거기서 본 "90% 잔존"은 하필 정상조건 셀 하나만 본 편향치. 전체를 엄밀히 재면 80% 밖(90% 아님).

⚠ 발표 방어선 — 결과의 신뢰도는 귀무 2.1%가 낮다는 데 달림. 귀무가 15~20%였다면 "관측 20%"는 싱글톤 아티팩트로 무너짐. 2.1%라 관측 20%의 대부분이 진짜 ODD 신호임이 보장됨. 코드: analysis_two_lens.py :: analysis4_eta_squared .